

Lead**Flow** Automation

AI-rendszerek, amelyek a cég **saját adatain** futnak

Zárt hálózaton futó AI: kódbasis-térkép, tudásbázis és fejlesztői ügynökök — külső szolgáltatás nélkül.

PhD · Cambridge

7 szabadalom

10+ év AI

zárt hálózaton is futtatható

Ki áll a munka mögött

Biztonságkritikus mérnöki múlt

15 év kutatás-fejlesztés ipari környezetben: biztonságkritikus szoftverfejlesztés, **redundáns rendszerek**, jelfeldolgozás.

Vezetéstámogató és **önvezető rendszerek algoritmusfejlesztése** — ahol a hibás kimenetnek fizikai következménye van, és ezt a fejlesztési folyamatnak kell kizárnia.

PhD, Cambridge · MEng, UCL · **7 szabadalom**

10+ év AI-fejlesztés

Gépi tanulási modellek · **AI-integráció kkv-knál** · értékesítés-automatizálás · előrejelzés · **AI-ügynöksapatok fejlesztése** · vállalati tudásbázisok (RAG).

Az elmúlt három év kizárólag **nagy nyelvi modellekre épülő rendszerekről** szól: kormányzott AI-kapuk, ügynökrétegek, saját környezetben futó megoldások.

Éles rendszerek, napi használatban



Amerikai elektronikai gyártó

Két éles RAG-rendszer a mérnöki szervezetnél, **5000+ dokumentumon**, napi használatban **2026 áprilisa óta**.

Kötelező forrásmegjelölés, kiértékelő keretrendszer a bevezetés előtt.

5000+ dokumentum

napi használat



Európai ipari kereskedőcég

Szabályozott AI-platform a megrendelő **saját felhőkörnyezetében**: egyetlen ellenőrzött hívási pont, adatkitakarás, naplózás, emberi jóváhagyás.

Egy héttel az élesítés után az AI-használat 10%-ról 90%-ra nőtt.

10% → 90% egy hét alatt

0 személyes adat a hívásban



Saját fejlesztés · jogi terület

„AI ügyvédjelölt” ügyvédi irodai munkára: precedenskeresés, **érvelési ügynökök**, fellebbezéstervezetet előállító ügynökcsapat.

Saját termékfejlesztés, **nem ügyfélprojekt** — azt mutatja, meddig visznek el az ügynökcsapatok egy erősen szabályozott, hivatkozásalapú szakmában.

jogpilot.ai

saját fejlesztés



Brit tanácsadó cég

A cég **teljes módszertana** tudásbázisban, ügynökökkel — a csapat a **megszokott ChatGPT-felületről** éri el.

Az ügyfél a tőlünk kapott forráskódra **saját eszközöket is épített**.

napi használat



Saját termék · e-kereskedelem

Többügynökös gyártási lánc a koncepciótól a publikálható termékig.

4 óra → 12 perc / termék

97 leszállított termék

Amit őszintén hozzá kell tenni

Ezek közül **egy sem zárt hálózaton futott**: van köztük felhős modellre épülő és saját környezetben futó is.

Ami mindegyikben közös: **forrásmegjelölés**, jogosultság szerinti hozzáférés, és emberi jóváhagyás a következményes lépéseknél. **A zárt hálózatú működést a 0. fázis hivatott bizonyítani** — az Önök kódján.

Hol vannak az ügynökök — és mi fogja őket vissza

AZ ÖNÖK CSAPATA

Fejlesztői környezet (IDE)

Saját chat-felület

Ügynökcsapatok

Ütemezett feladatok

AI-KAPU

Készségréteg (skill layer)

folyamatonként leírt, verziózott ügynök-készségek

Eszközszervert (MCP)

legsúlykebb jogosultság · minden eszközhívás naplózva

Kormányzás

kifelé nincs hálózati hívás — a modell is bent fut
emberi jóváhagyás a következményes lépéseknél
teljes, visszakövethető auditnyomvonal

AZ ÖNÖK RENDSZEREI (ZÁRT HÁLÓZAT)

Dokumentumok

Kódbázis


ERP · belső rendszerek

Levelezés · fájlserver

A modell soha nem ér hozzá közvetlenül semmihez — mindig a kapun keresztül dolgozik

Ma emberek fejében van, ami a gépen is lehetne

- **Több évtizedes kódbázis**, vegyes nyelvek és korok — teljes térkép nincs róla.
- **Felhős AI kizárva**: nem kockázatkezelés, hanem előfeltétel.
- A dokumentáció és a kód **külön világ**: ami össze van kötve, az a fejekben van.



Ugyanez a háló géppel olvasható — ezért lehet rákérdezni, és ezért látszik, mit visz magával egy változtatás

Négy réteg, mind a zárt hálózaton belül



Először a kicsi lépés — és igen, ehhez is kell gép

0. fázis · 2–3 hét

Egy munkaállomás-kategóriájú GPU elég — kölcsöngépen vagy egy meglévő fejlesztői vason, az Önök hálózatán belül. Kis modell, egy reprezentatív modul.

Eredmény: első kódgráf **lefedettségi mutatóval** (nyelvenként hány % oldható fel gépileg), és egy működő, zárt láncú prototípus.

Ha ez nem győz meg, itt megállunk — ez a lépés önmagában is értéket ad.

1. fázis · 2–3 hónap

A 0. fázis mérései alapján méretezett szerver. Nem előre veszünk hardvert: a lefedettség és a tényleges terhelés dönti el, egy vagy két GPU kell.

Offline modell- és csomagtükrök, teljes kódgráf, tudásbázis, és **csak olvasó** programozástámogató ügynök egy pilotcsoportnak.

2. fázis

Helyi kódoló ügynök, **először csak javaslattevő módban**. Bővítés kizárólag nem kritikus kódon, mért eredmény alapján.

Biztonságkritikus modulon az ügynök nem dolgozik önállóan.

Amit előre tudni kell: a régi nyelvek — különösen a **COBOL** és a **VB6** — gépi feltérképezése hiányos lesz, ott kézi ellenőrzés kell; a lefedettségi mutató pont ezt méri. **A sorrend nem véletlen.** A hardverdöntés a legdrágább és a legnehezebben visszacsinálható lépés — ezért az utolsó, nem az első. A 0. fázisban azt mérjük meg, amiből a méretezés egyáltalán számolható.

Konkrétan mi legyen az első három hét

Amit mi csinálunk

1. Kiválasztunk Önökkel **egy modult**, ami elég fontos, hogy számítson, és elég kicsi, hogy átlátható legyen.
2. Felépítjük rá a **kódgráfot**, és megmérjük, nyelvenként hány százalékot sikerült gépileg feloldani.
3. Betöltjük a modulhoz tartozó **dokumentációt**, és felállítunk egy zárt láncú kérdező prototípust.
4. Írásban átadjuk, **mi nem működött**, és mi az, ami csak kézzel oldható meg.

Amit Önök kapnak

Lefedettségi jelentés — nyelvenkénti számokkal, nem szöveges ígérettel.

Működő prototípus a saját hálózatukon, a saját kódjukon és dokumentációjukon.

Méretezési számítás — ebből derül ki, mekkora gép kell az éles rendszerhez, és mennyibe kerül.

Kockázati jegyzék: hol lesz kézi munka, mit nem vállalunk, és mit kell Önöknek eldönteni.

Ez az anyag akkor is az Önöké, ha nem megyünk tovább.

Amire szükségünk lesz: hozzáférés egy modulhoz és a dokumentációjához · egy **a régi nyelveket ismerő fejlesztő** heti 2–3 órában · egy gép a hálózaton belül · és egy **biztonsági jóváhagyás** arra, hogyan visszük be a modellsúlyokat és a csomagokat a zárt hálózatba (aláírt csomagként, egyirányú átvitelrel).

Méretezés — a számítás, nem csak a végeredmény

Feltételezés (pesszimista)	Érték	Miből jön
Elvárt sebesség	40–50 token/mp / fő	Ennyit ad ma a felhős Claude Sonnet is (~41–53 token/mp, Artificial Analysis 2026) — helyben ugyanennyi paritást jelent, nem visszalépést . Pusztá olvasáshoz 20–25 is elég volna, de ügynökös munkánál a fejlesztő nem olvas, hanem vár
Egyidejűség	a csapat 40%-a	Nem mindenki küld egyszerre kérést; 40% terhelési csúcsnak pesszimista
Egy 96 GB-os GPU összesített áteresztése	≈ 4 000–6 000 token/mp	30B körüli, kvantált nyílt kódmodellen, kötegelt kiszolgálással
RAG-válasz	300–800 token, 30 token/mp	Rövid, hivatkozott válasz — nem hosszú generálás
Kontextusablak memóriaigénye	több GB / egyidejű munkamenet	Ez korlátoz előbb, mint a sebesség — ezért kell a második kártya

10 fejlesztő

Csúcson 4 egyidejű kérés × 50 token/mp = **200 token/mp** — egy GPU áteresztésének töredéke.

30 fejlesztő

Csúcson 12 × 50 = **600 token/mp** — egy kártya sebességének töredéke. **A korlát nem itt van:** 12 párhuzamos, hosszú kontextusú munkamenet memóriája nem fér el egy kártyán, és tartalék sincs. **Ezért kettő.**

100–150 RAG-felhasználó

Belőlük **15–20 kérdez egyszerre** × 30 token/mp = **450–600 token/mp**. Egy GPU elég; a szűk keresztmetszet **a keresés és az indexelés, nem a modell**.

A sebesség **munkamenetenként, csúcsterhelésen** értendő — nem egyetlen felhasználóra mért csúcserték. Hosszú kontextusnál a **válasz előtti feldolgozási idő** külön tétel, ezt a 0. fázisban mérjük. A számok **mai nagyságrendek, mérés nélkül**, nem ajánlat.

Három méret — ugyanaz a szoftver, más vas

0. fázis — mérés

1 db munkaállomás-GPU (24–48 GB)

kis kódmodell, egy modul

meglévő vagy kölcsöngép

≈ 0 beruházás

5–10 fejlesztő

1× 96 GB GPU

32 mag CPU · 256 GB RAM · 4 TB NVMe

ugyanaz kiszolgál 100–150 RAG-felhasználót

≈ €25–30 ezer

20–30 fejlesztő

2× 96 GB GPU

64 mag CPU · 512 GB RAM · 8 TB NVMe

tartalék kapacitás és nagyobb kontextus

≈ €45–55 ezer

Ami az árban nincs benne

Szünetmentes táp, hálózat, rack, hűtés és üzemeltetés. Egy GPU-s gép terhelés alatt nagyságrendileg **1–1,5 kW**, a kétkártyás ennek közel a duplája.

Miért nem adatközponti kártyával számolunk

Ezen a terhelésen **nem az áteresztés a szűk keresztmetszet**, hanem a memória és az üzemeltetés. A drágább adatközponti kártya itt nem vásárol több használhatóságot.