

Lead**Flow** Automation

AI-rendszerek, amelyek a cég **saját adatain** futnak

Zárt hálózaton futó AI: kódrendszer-térkép, tudásbázis és fejlesztői ügynökök — külső szolgáltatás nélkül.

PhD · Cambridge

7 szabadalom

10+ év AI

zárt hálózaton is futtatható



Ki vagyok

Biztonságkritikus mérnöki múlt

15 év kutatás-fejlesztés ipari környezetben: biztonságkritikus szoftverfejlesztés, **redundáns rendszerek**, jelfeldolgozás.

Vezetéstámogató és **önvezető rendszerek algoritmusfejlesztése** — ahol a hibás kimenetnek fizikai következménye van, és ezt a fejlesztési folyamatnak kell kizárnia.

PhD, Cambridge · MEng, UCL · **7 szabadalom**

10+ év AI-fejlesztés

Gépi tanulási modellek · **AI-integráció kkv-knál** · értékesítés-automatizálás · előrejelzés · **AI-ügynöksapatok fejlesztése** · vállalati tudásbázisok (RAG).

Az elmúlt három év kizárólag **nagy nyelvi modellekre épülő rendszerekről** szól: kormányzott AI-kapuk, ügynökrétegek, saját környezetben futó megoldások.

Referenciák



Amerikai elektronikai gyártó

Két éles RAG-rendszer a mérnöki szervezetnél, **5000+ dokumentumon**, napi használatban **2026 áprilisa óta**.

Kötelező forrásmegjelölés, kiértékelő keretrendszer a bevezetés előtt.

5000+ dokumentum

napi használat



Európai ipari kereskedőcég

Szabályozott AI-platform a megrendelő **saját felhőkörnyezetében**: egyetlen ellenőrzött hívási pont, adatkitakarás, naplózás, emberi jóváhagyás.

Egy héttel az élesítés után az AI-használat 10%-ról 90%-ra nőtt.

10% → 90% egy hét alatt

0 személyes adat a hívásban



Magyar ügyvédi iroda

„AI ügyvédjelölt” napi használatban: precedenskeresés, **érvelési ügynökök**, és teljes **fellebbezésstervezetet előállító ügynökcsapat**.

Erősen szabályozott, hivatkozásalapú szakma — minden állítás visszavezethető a forrásig, a felelősség az ügyvédé marad.

jogpilot.ai

napi használat



Brit tanácsadó cég

A cég **teljes módszertana** tudásbázisban, ügynökökkel — a csapat a **megszokott ChatGPT-felületről** éri el.

Az ügyfél a tőlünk kapott forráskódra **saját eszközöket is épített**.

napi használat



ScalePod · saját termék

MCP-szerver és eszköz-szerver mögött több ügynök dolgozik együtt: piackutatás, terv, nyomdakész fájl, termékleírás, publikálás — egy láncban, emberi jóváhagyási pontokkal.

4 óra → 12 perc / termék

97 leszállított termék

Agentikus AI architektúra

AZ ÖNÖK CSAPATA

Fejlesztői környezet (IDE)

Saját chat-felület

Ügynökcsapatok

Ütemezett feladatok

AI-KAPU

Készségréteg (skill layer)

folyamatonként leírt, verziózott ügynök-készségek

Eszközszervert (MCP)

legsúlykebb jogosultság · minden eszközhívás naplózva

Kormányzás

kifelé nincs hálózati hívás — a modell is bent fut
emberi jóváhagyás a következményes lépéseknél
teljes, visszakövethető auditnyomvonal

AZ ÖNÖK RENDSZEREI (ZÁRT HÁLÓZAT)

Dokumentumok

Kódbázis


ERP · belső rendszerek

Levelezés · fájlserver


A modell soha nem ér hozzá közvetlenül semmihez — mindig a kapun keresztül dolgozik

A kódbázis mint összefüggő háló

- **Több évtizedes kódbázis,** vegyes nyelvek — teljes térkép nincs róla.
- **Felhős AI kizárva:** nem kockázatkezelés, hanem előfeltétel.
- A dokumentáció és a kód **külön világ:** ami össze van kötve, az a fejekben van.



Legacy kódbázis: tudásbázis + fejlesztői támogatás



A szaggatott kereten belül minden az Önök hálózatán fut — kifelé nincs hívás

Bevezetési fázisok

0. fázis • 2–3 hét

Egy munkaállomás-kategóriájú GPU elég — kölcsöngépen vagy egy meglévő fejlesztői vason, az Önök hálózatán belül. Kis modell, egy reprezentatív modul.

Eredmény: első kódgráf **lefedettségi mutatóval** (nyelvenként hány % oldható fel gépileg), és egy működő, zárt láncú prototípus.

Ha ez nem győz meg, itt megállunk — ez a lépés önmagában is értéket ad.

1. fázis • 2–3 hónap

A 0. fázis mérései alapján méretezett szerver. Nem előre veszünk hardvert: a lefedettség és a tényleges terhelés dönti el, egy vagy két GPU kell.

Offline modell- és csomagtükröz, teljes kódgráf, tudásbázis, és **csak olvasó** programozástámogató ügynök egy pilotcsoportnak.

2. fázis

Helyi kódoló ügynök, **először csak javaslattevő módban**. Bővítés kizárólag nem kritikus kódon, mért eredmény alapján.

Biztonságkritikus modulon az ügynök nem dolgozik önállóan.

Amit előre tudni kell: a kódbázis **Delphi, Java, kevés C++ és Python**. A Java és a Python jól támogatott; **a Delphi a kockázat** — az eseménykötés a form-fájlokban él, a feltételes fordítás miatt pedig fordítási változatokként külön gráf készül. A lefedettségi mutató pont ezt méri. **A sorrend nem véletlen.** A hardverdöntés a legdrágább és a legnehezebben visszacsinálható lépés — ezért az utolsó, nem az első. A 0. fázisban azt mérjük meg, amiből a méretezés egyáltalán számolható.

Projekt javaslat

Amit mi csinálunk

1. Kiválasztunk Önökkel **egy modult**, ami elég fontos, hogy számítson, és elég kicsi, hogy átlátható legyen.
2. Felépítjük rá a **kódgráfot**, és megmérjük, nyelvenként hány százalékot sikerült gépileg feloldani.
3. Betöltjük a modulhoz tartozó **dokumentációt**, és felállítunk egy zárt láncú kérdező prototípust.
4. Írásban átadjuk, **mi nem működött**, és mi az, ami csak kézzel oldható meg.

Amit Önök kapnak

Lefedettségi jelentés — nyelvenkénti számokkal, nem szöveges ígérettel.

Működő prototípus a saját hálózatukon, a saját kódjukon és dokumentációjukon.

Méretezési számítás — ebből derül ki, mekkora gép kell az éles rendszerhez, és mennyibe kerül.

Kockázati jegyzék: hol lesz kézi munka, mit nem vállalunk, és mit kell Önöknek eldönteni.

Ez az anyag akkor is az Önöké, ha nem megyünk tovább.

Amire szükségünk lesz: hozzáférés egy modulhoz és a dokumentációjához · egy **a régi nyelveket ismerő fejlesztő** heti 2–3 órában · egy gép a hálózaton belül · és egy **biztonsági jóváhagyás** arra, hogyan visszük be a modellsúlyokat és a csomagokat a zárt hálózatba (aláírt csomagként, egyirányú átvitelrel).

Méretezés a tényleges csapatra

A valós terhelés	Érték	Megjegyzés
Párhuzamos kódoló munkamenet	max. 3	3 fejlesztő; a tesztelők és az architekt szakaszosan dolgoznak
Tudásbázis-használat	5 fő	Rövid, hivatkozott válaszok — nem tartós generálás
Kontextus	64 ezer token	Ügynökös munkánál reális

Modell	Sebesség 3 munkamenetnél	Memória munkamenetenként	Egyszerre kiszolgálható
35B, hibrid (ritka aktiválás)	213 token/mp	0,7 GB	81
27B, klasszikus sűrű	40 token/mp	2,7 GB	23
32B, klasszikus sűrű	24 token/mp	8,0 GB	7

A „kisebb” modell itt a rosszabb választás. A sűrű 27B minden tokennél a teljes modellt mozgatja, a hibrid 35B csak a töredékét — ezért 5–9-szer lassabb felhasználónként, és 4–12-szer több memóriát eszik. Nem a paraméterszám dönt. Mindkettőt lemérjük a saját kódjukon, mielőtt bármit rögzítünk.

Két konfiguráció, magyar árakon

Konfiguráció	Bruttó	Nettó	Csak a kártya meglévő gépbe	Fogyasztás
A — 2× RTX 5090 (2×32 GB)	8,86 M Ft	6,97 M Ft	3,75 M Ft	1,65 kW
B — 1× RTX PRO 6000 (96 GB)	11,93 M Ft	9,39 M Ft	6,90 M Ft	0,80 kW
C — 1× RTX PRO 5000 (48 GB) ★	árajánlat alatt	≈ B fele	—	0,30 kW

Miért a 48 GB-os az ajánlat

3 párhuzamos munkamenetnél **159 token/mp** felhasználónként — bőven a küszöb fölött. **Nem kell két kártya közé szétvágni a modellt**, fele annyit fogyaszt, és virtualizált környezetben támogatott.

A beszerzés többet számít, mint a kártya

A magyar csatornaár **23–81%-kal az uniós piaci ár fölött** van. Közösségi beszerzéssel **egyetlen kártyán 3–4,5 millió forint** takarítható meg — ez nagyobb tétel, mint a kártyák közti választás.

Két kártya nem fél ár. A memória lineárisan árazott: két 48 GB-os kártya ugyanannyiba kerül, mint egy 96 GB-os. **AMD-kártya virtualizált környezetben nem opció** — a Radeon vonalon nincs a hardvermegosztáshoz szükséges támogatás, és a választott modellhez sincs bejáratott kiszolgálás.