

Lead**Flow** Automation

AI-rendszerek, amelyek a cég **saját adatain** futnak

Zárt hálózaton futó AI: kódbasis-térkép, tudásbázis és fejlesztői ügynökök — külső szolgáltatás nélkül.

PhD · Cambridge

7 szabadalom

10+ év AI

zárt hálózaton is futtatható



Ki vagyok

Biztonságkritikus mérnöki múlt

15 év kutatás-fejlesztés ipari környezetben: biztonságkritikus szoftverfejlesztés, **redundáns rendszerek**, jelfeldolgozás.

Vezetéstámogató és **önvezető rendszerek algoritmusfejlesztése** — ahol a hibás kimenetnek fizikai következménye van, és ezt a fejlesztési folyamatnak kell kizárnia.

PhD, Cambridge · MEng, UCL · **7 szabadalom**

10+ év AI-fejlesztés

Gépi tanulási modellek · **AI-integráció kkv-knál** · értékesítés-automatizálás · előrejelzés · **AI-ügynöksapatok fejlesztése** · vállalati tudásbázisok (RAG).

Az elmúlt három év kizárólag **nagy nyelvi modellekre épülő rendszerekről** szól: kormányzott AI-kapuk, ügynökrétegek, saját környezetben futó megoldások.

Referenciák



Amerikai elektronikai gyártó

Két éles RAG-rendszer a mérnöki szervezetnél, **5000+ dokumentumon**, napi használatban **2026 áprilisa óta**.

Kötelező forrásmegjelölés, kiértékelő keretrendszer a bevezetés előtt.

5000+ dokumentum

napi használat



Európai ipari kereskedőcég

Szabályozott AI-platform a megrendelő **saját felhőkörnyezetében**: egyetlen ellenőrzött hívási pont, adatkitakarás, naplózás, emberi jóváhagyás.

Egy héttel az élesítés után az AI-használat 10%-ról 90%-ra nőtt.

10% → 90% egy hét alatt

0 személyes adat a hívásban



Saját fejlesztés · jogi terület

„AI ügyvédjelölt” ügyvédi irodai munkára: precedenskeresés, **érvelési ügynökök**, fellebbezéstervezetet előállító ügynökcsapat.

Saját termékfejlesztés, **nem ügyfélprojekt** — azt mutatja, meddig visznek el az ügynökcsapatok egy erősen szabályozott, hivatkozásalapú szakmában.

jogpilot.ai

saját fejlesztés



Brit tanácsadó cég

A cég **teljes módszertana** tudásbázisban, ügynökökkel — a csapat a **megszokott ChatGPT-felületről** éri el.

Az ügyfél a tőlünk kapott forráskódra **saját eszközöket is épített**.

napi használat



Saját termék · e-kereskedelem

Többügynökös gyártási lánc a koncepciótól a publikálható termékig.

4 óra → 12 perc / termék

97 leszállított termék

Amit őszintén hozzá kell tenni

Ezek közül **egy sem zárt hálózaton futott**: van köztük felhős modellre épülő és saját környezetben futó is.

Ami mindegyikben közös: **forrásmegjelölés**, jogosultság szerinti hozzáférés, és emberi jóváhagyás a következményes lépéseknél. **A zárt hálózatú működést a 0. fázis hivatott bizonyítani** — az Önök kódján.

Hol vannak az ügynökök

AZ ÖNÖK CSAPATA

Fejlesztői környezet (IDE)

Saját chat-felület

Ügynökcsapatok

Ütemezett feladatok

AI-KAPU

Készségréteg (skill layer)

folyamatonként leírt, verziózott ügynök-készségek

Eszközszervert (MCP)

legsúlykebb jogosultság · minden eszközhívás naplózva

Kormányzás

kifelé nincs hálózati hívás — a modell is bent fut
emberi jóváhagyás a következményes lépéseknél
teljes, visszakövethető auditnyomvonal

AZ ÖNÖK RENDSZEREI (ZÁRT HÁLÓZAT)

Dokumentumok

Kódbázis


ERP · belső rendszerek

Levelezés · fájlserver

A modell soha nem ér hozzá közvetlenül semmihez — mindig a kapun keresztül dolgozik


Ami ma a fejekben van

- **Több évtizedes kódbázis**, vegyes nyelvek és korok — teljes térkép nincs róla.
- **Felhős AI kizárva**: nem kockázatkezelés, hanem előfeltétel.
- A dokumentáció és a kód **külön világ**: ami össze van kötve, az a fejekben van.



Ugyanez a háló géppel olvasható — ezért lehet rákérdezni, és ezért látszik, mit visz magával egy változtatás

Négy réteg, zárt hálózaton



A szaggatott kereten belül minden az Önök hálózatán fut — kifelé nincs hívás

Bevezetés három lépésben

0. fázis • 2–3 hét

Egy munkaállomás-kategóriájú GPU elég — kölcsöngépen vagy egy meglévő fejlesztői vason, az Önök hálózatán belül. Kis modell, egy reprezentatív modul.

Eredmény: első kódgráf **lefedettségi mutatóval** (nyelvenként hány % oldható fel gépileg), és egy működő, zárt láncú prototípus.

Ha ez nem győz meg, itt megállunk — ez a lépés önmagában is értéket ad.

1. fázis • 2–3 hónap

A 0. fázis mérései alapján méretezett szerver. Nem előre veszünk hardvert: a lefedettség és a tényleges terhelés dönti el, egy vagy két GPU kell.

Offline modell- és csomagtükrök, teljes kódgráf, tudásbázis, és **csak olvasó** programozástámogató ügynök egy pilotcsoportnak.

2. fázis

Helyi kódoló ügynök, **először csak javaslattevő módban**. Bővítés kizárólag nem kritikus kódon, mért eredmény alapján.

Biztonságkritikus modulon az ügynök nem dolgozik önállóan.

Amit előre tudni kell: a régi nyelvek — különösen a **COBOL és a VB6** — gépi feltérképezése hiányos lesz, ott kézi ellenőrzés kell; a lefedettségi mutató pont ezt méri. **A sorrend nem véletlen.** A hardverdöntés a legdrágább és a legnehezebben visszacsinálható lépés — ezért az utolsó, nem az első. A 0. fázisban azt mérjük meg, amiből a méretezés egyáltalán számolható.

Az első három hét

Amit mi csinálunk

1. Kiválasztunk Önökkel **egy modult**, ami elég fontos, hogy számítson, és elég kicsi, hogy átlátható legyen.
2. Felépítjük rá a **kódgráfot**, és megmérjük, nyelvenként hány százalékot sikerült gépileg feloldani.
3. Betöltjük a modulhoz tartozó **dokumentációt**, és felállítunk egy zárt láncú kérdező prototípust.
4. Írásban átadjuk, **mi nem működött**, és mi az, ami csak kézzel oldható meg.

Amit Önök kapnak

Lefedettségi jelentés — nyelvenkénti számokkal, nem szöveges ígérettel.

Működő prototípus a saját hálózatukon, a saját kódjukon és dokumentációjukon.

Méretezési számítás — ebből derül ki, mekkora gép kell az éles rendszerhez, és mennyibe kerül.

Kockázati jegyzék: hol lesz kézi munka, mit nem vállalunk, és mit kell Önöknek eldönteni.

Ez az anyag akkor is az Önöké, ha nem megyünk tovább.

Amire szükségünk lesz: hozzáférés egy modulhoz és a dokumentációjához · egy **a régi nyelveket ismerő fejlesztő** heti 2–3 órában · egy gép a hálózaton belül · és egy **biztonsági jóváhagyás** arra, hogyan visszük be a modellsúlyokat és a csomagokat a zárt hálózatba (aláírt csomagként, egyirányú átvitelrel).

Méretezés 50 fejlesztőre

Amit feltételezünk	Érték	Miből jön
Egyidejűség	50 munkamenet	Napi 5–7 óra folyamatos ügynökös munka — ez nem csúcs, hanem tartós állapot. A korábbi 40%-os becslés 2–2,5×-sel alábecsülte a terhelést
Ebből egyszerre generál	~41	Az ügynök idejének nagy része modellgenerálás; a várakozó munkamenet memóriát foglal, sávszélességet nem
Kontextus munkamenetenként	64 ezer token	Ügynökös munkánál reális; ez határozza meg a gyorsítótár méretét
Modell	35B, hibrid figyelem	Nyílt súlyú kódmodell, FP8-ban. 40 rétegeből csak 10 tart növekvő gyorsítótárat — ez a felépítés dönti el a hardverigényt
Elvárt sebesség	40–50 token/mp	Ennyit ad ma a felhős Claude Sonnet is — helyben ugyanennyi paritás, nem visszalépés

A modellválasztás többet ér a hardvernél

64 ezres kontextuson 0,7 GB munkamenetenként a hibrid felépítésű modellel — ugyanez klasszikus felépítéssel 3–11,5 GB. Nem a paraméterszám dönt, hanem a rétegszám és a figyelmi felépítés.

A férőhely csal

Két kártyán 156 munkamenet elférne, de csak 53 szolgálható ki 40 token/mp-pel. A korlát a memória sávszélessége, nem a hely — a férőhely közel háromszorosan túlbecsüli a valóságot.

Ezért 50 főre

Három professzionális kártya fedi le tartalékkal, hosszabb kontextussal együtt is. A pontos szám a saját kódjukon mért kontextushossztól függ — ezt méri a pilot.

A számítás módszere: modell súlyai → gyorsítótár munkamenetenként → ebből a férőhely → és csak ezután a sebesség. Levezetve, ellenőrizhető formában átadjuk.

Mit kapunk a pénzért

Konfiguráció	Beruházás	Kiszolgált munkamenet	Fogyasztás	Amit tudni kell
1 kártya — pilot	€29–33 ezer	26	1,1 kW	A csapat fele; ezen mérjük meg a valódi számokat
2 kártya	€51–57 ezer	53	1,7 kW	Épphogy fedi az 50 főt — tartalék nélkül, és 128 ezres kontextusnál kevés
3 kártya ★	€70–78 ezer	80	2,3 kW	Tartalékkal, hosszabb kontextussal is — és elég hozzá egy normál 16A áramkör
4 kártyás szerver	€95–108 ezer	107	3,0 kW	Rack és dedikált betáp; már bőven a szükséges fölött
1 DGX Station	€107–134 ezer	163	1,6 kW	Akkor éri meg, ha a modell nem fér el egy kártyán; egy gép, tartalék nélkül

Egy munkamenet ára

A javasolt méretben **nagyságrendileg €900 munkamenetenként**. A döntés nem ár-érték arányról szól — az áramról, a tartalékról és az üzemeltetésről.

Kvantálás nem spórol hardvert

A 4 bites tömörítés **ugyanennyi kártyát igényel**, mert nem a férőhely a korlát. Cserébe **mérhetetlen minőségi kockázatot** visz a régi nyelveken — ezért FP8-at javasunk.

Az árak tartalmazzák a teljes gépet és a szünetmentes tápot; **a rack, a hűtés bővítése és az üzemeltetés nem**. Tisztán költségalapon a felhős szolgáltatás minden méretnél olcsóbb — **itt a szuverenitás az indok, nem a megtakarítás**, és ezt nem is állítjuk másképp.