

Lead**Flow** Automation

AI-rendszerek, amelyek a cég **saját adatain** futnak

Zárt hálózaton futó AI: kódbasis-térkép, tudásbázis és fejlesztői ügynökök — külső szolgáltatás nélkül.

PhD · Cambridge

7 szabadalom

10+ év AI

zárt hálózaton is futtatható

Ki áll a munka mögött

Biztonságkritikus mérnöki múlt

15 év kutatás-fejlesztés ipari környezetben: biztonságkritikus szoftverfejlesztés, **redundáns rendszerek**, jelfeldolgozás.

Vezetéstámogató és **önvezető rendszerek algoritmusfejlesztése** — ahol a hibás kimenetnek fizikai következménye van, és ezt a fejlesztési folyamatnak kell kizárnia.

PhD, Cambridge · MEng, UCL · **7 szabadalom**

10+ év AI-fejlesztés

Gépi tanulási modellek · **AI-integráció kkv-knál** · értékesítés-automatizálás · előrejelzés · **AI-ügynöksapatok fejlesztése** · vállalati tudásbázisok (RAG).

Az elmúlt három év kizárólag **nagy nyelvi modellekre épülő rendszerekről** szól: kormányzott AI-kapuk, ügynökrétegek, saját környezetben futó megoldások.

Éles rendszerek, napi használatban



Amerikai elektronikai gyártó

Két éles RAG-rendszer a mérnöki szervezetnél, **5000+ dokumentumon**, napi használatban **2026 áprilisa óta**.

Kötelező forrásmegjelölés, kiértékelő keretrendszer a bevezetés előtt.

5000+ dokumentum

napi használat



Európai ipari kereskedőcég

Szabályozott AI-platform a megrendelő **saját felhőkörnyezetében**: egyetlen ellenőrzött hívási pont, adatkitakarás, naplózás, emberi jóváhagyás.

Egy héttel az élesítés után az AI-használat 10%-ról 90%-ra nőtt.

10% → 90% egy hét alatt

0 személyes adat a hívásban



Magyar ügyvédi iroda

Saját fejlesztésű „**AI ügyvédjelölt**”: precedenskeresés, **érvelési ügynökök**, és teljes **fellebbezésstervezetet előállító ügynökcsapat**.

Minden hivatkozás visszavezethető a forrásig; a jogi felelősség az ügyvédé marad.

jogpilot.ai

precedens + érvelés



Brit tanácsadó cég

A cég **teljes módszertana** tudásbázisban, ügynökökkel — a csapat a **megszokott ChatGPT-felületről** éri el.

Az ügyfél a tőlünk kapott forráskódra **saját eszközöket is épített**.

napi használat



Saját termék · e-kereskedelem

Többügynökös gyártási lánc a koncepciótól a publikálható termékig.

4 óra → 12 perc / termék

97 leszállított termék

Közös bennük

Mindegyik a megrendelő **saját környezetében** fut, **forrásmegjelöléssel** dolgozik, és a következményekkel járó lépésnél **embert kérdez**.

Hol vannak az ügynökök — és mi fogja őket vissza

AZ ÖNÖK CSAPATA



AI-KAPU

Készség-réteg (skill layer)

folyamatonként leírt, verziózott ügynök-készségek

Eszköz-szerver (MCP)

legszűkebb jogosultság · minden eszközhívás naplózva

Kormányzás

személyes adat kitakarása a hívás előtt
emberi jóváhagyás a következményes lépéseknél
teljes, visszakövethető auditnyomvonal

AZ ÖNÖK RENDSZEREI



A modell soha nem ér hozzá közvetlenül semmihez — mindig a kapun keresztül dolgozik


Ma emberek fejében van, ami a gépen is lehetne

- **Több évtizedes kódbázis**, vegyes nyelvek és korok — teljes térkép nincs róla.
- **Felhős AI kizárva**: nem kockázatkezelés, hanem előfeltétel.
- A dokumentáció és a kód **külön világ**: ami össze van kötve, az a fejekben van.



Ugyanez a háló géppel olvasható — ezért lehet rákérdezni, és ezért látszik, mit visz magával egy változtatás

Négy réteg, mind a zárt hálózaton belül



Először a kicsi lépés — és igen, ehhez is kell gép

0. fázis · 2–3 hét

Egy munkaállomás-kategóriájú GPU elég — kölcsöngépen vagy egy meglévő fejlesztői vason, az Önök hálózatán belül. Kis modell, egy reprezentatív modul.

Eredmény: első kód-gráf **lefedettségi mutatóval** (nyelvenként hány % oldható fel gépileg), és egy működő, zárt láncú prototípus.

Ha ez nem győz meg, itt megállunk — ez a lépés önmagában is értéket ad.

1. fázis · 2–3 hónap

A 0. fázis mérései alapján méretezett szerver. Nem előre veszünk hardvert: a lefedettség és a tényleges terhelés dönti el, egy vagy két GPU kell.

Offline modell- és csomagtükkör, teljes kód-gráf, tudásbázis, és **csak olvasó** programozástámogató ügynök egy pilotcsoportnak.

2. fázis

Helyi kódoló ügynök, **először csak javaslattevő módban**. Bővítés kizárólag nem kritikus kódon, mért eredmény alapján.

Biztonságkritikus modulon az ügynök nem dolgozik önállóan.

A sorrend nem véletlen. A hardverdöntés a legdrágább és a legnehezebben visszacsinálható lépés — ezért az utolsó, nem az első. A 0. fázisban azt mérjük meg, amiből a méretezés egyáltalán számolható.

Konkrétan mi legyen az első három hét

Amit mi csinálunk

1. Kiválasztunk Önökkel **egy modult**, ami elég fontos, hogy számítson, és elég kicsi, hogy átlátható legyen.
2. Felépítjük rá a **kód-gráfot**, és megmérjük, nyelvenként hány százalékot sikerült gépileg feloldani.
3. Betöltjük a modulhoz tartozó **dokumentációt**, és felállítunk egy zárt láncú kérdező prototípust.
4. Írásban átadjuk, **mi nem működött**, és mi az, ami csak kézzel oldható meg.

Amit Önök kapnak

Lefedettségi jelentés — nyelvenkénti számokkal, nem szöveges ígérettel.

Működő prototípus a saját hálózatukon, a saját kódjukon és dokumentációjukon.

Méretezési számítás — ebből derül ki, mekkora gép kell az éles rendszerhez, és mennyibe kerül.

Kockázati jegyzék: hol lesz kézi munka, mit nem vállalunk, és mit kell Önöknek eldönteni.

Ez az anyag akkor is az Önöké, ha nem megyünk tovább.

Amire szükségünk lesz: hozzáférés egy modulhoz és a hozzá tartozó dokumentációhoz, egy kapcsolattartó fejlesztő heti 2–3 órában, és egy gép a hálózaton belül, amin futtathatunk. Semmi más.

Méretezés — a számítás, nem csak a végeredmény

Feltételezés (pesszimista)	Érték	Miből jön
Elvárt sebesség	40–50 token/mp / fő	Ennél lassabb esetén a fejlesztő elkapcsol — ez a használhatóság küszöbe
Egyidejűség	a csapat 40%-a	Nem mindenki küld egyszerre kérést; 40% terhelési csúcsnak pesszimista
Egy 96 GB-os GPU összesített áteresztése	≈ 4 000–6 000 token/mp	30B körüli, kvantált nyílt kódmodellen, kötegelt kiszolgálással
RAG-válasz	300–800 token, 30 token/mp	Rövid, hivatkozott válasz — nem hosszú generálás

10 fejlesztő

Csúcson 4 egyidejű kérés × 50 token/mp = **200 token/mp** — egy GPU áteresztésének töredéke.

30 fejlesztő

Csúcson 12 × 50 = **600 token/mp**. Áteresztésben még elférne egy kártyán, de **kontextus és tartalék miatt kettő a javaslat**.

150 RAG-felhasználó

50 egyidejű × 30 = **1 500 token/mp**. Egy GPU elég; a szűk keresztmetszet itt **a keresés, nem a modell**.

A számok **mai listaár-nagyságrendek és mérés nélküli becslések**, nem ajánlat. A 0. fázis pont azért van, hogy ezeket a saját kódjukon mért adatokra cseréljük.

Három méret — ugyanaz a szoftver, más vas

0. fázis — mérés

1 db munkaállomás-GPU (24–48 GB)
kis kódmodell, egy modul
meglévő vagy kölcsöngép

≈ 0 beruházás

5–10 fejlesztő

1× 96 GB GPU
32 mag CPU · 256 GB RAM · 4 TB NVMe
ugyanaz kiszolgál 100–150 RAG-felhasználót

≈ €25–30 ezer

20–30 fejlesztő

2× 96 GB GPU
64 mag CPU · 512 GB RAM · 8 TB NVMe
tartalék kapacitás és nagyobb kontextus

≈ €45–55 ezer

Ami az árban nincs benne

Szünetmentes táp, hálózat, rack, hűtés és üzemeltetés. Terhelés alatt **1–1,5 kW** fogyasztással érdemes számolni GPU-nként.

Miért nem H100-cal számolunk

Ezen a terhelésen **nem az áteresztés a szűk keresztmetszet**, hanem a memória és az üzemeltetés. A drágább adatközponti kártya itt nem vásárol több használhatóságot.