

Lead**Flow** Automation

AI-rendszerek, amelyek a cég **saját adatain** futnak

Márkabiztos AI-tartalom: gyors generálás, automatikus megfelelőségi ellenőrzés, emberi jóváhagyás.

PhD · Cambridge

7 szabadalom

10+ év AI

márkabiztos kimenet

Ki áll a munka mögött

Biztonságkritikus mérnöki múlt

15 év kutatás-fejlesztés ipari környezetben: biztonságkritikus szoftverfejlesztés, **redundáns rendszerek**, jelfeldolgozás.

Vezetéstámogató és **önvezető rendszerek algoritmusfejlesztése** — ahol a hibás kimenetnek fizikai következménye van, és ezt a fejlesztési folyamatnak kell kizárnia.

PhD, Cambridge · MEng, UCL · **7 szabadalom**

10+ év AI-fejlesztés

Gépi tanulási modellek · **AI-integráció kkv-knál** · értékesítés-automatizálás · előrejelzés · **AI-ügynöksapatok fejlesztése** · vállalati tudásbázisok (RAG).

Az elmúlt három év kizárólag **nagy nyelvi modellekre épülő rendszerekről** szól: kormányzott AI-kapuk, ügynökrétegek, saját környezetben futó megoldások.

Éles rendszerek, napi használatban



Amerikai elektronikai gyártó

Két éles RAG-rendszer a mérnöki szervezetnél, **5000+ dokumentumon**, napi használatban **2026 áprilisa óta**.

Kötelező forrásmegjelölés, kiértékelő keretrendszer a bevezetés előtt.

5000+ dokumentum

napi használat



Európai ipari kereskedőcég

Szabályozott AI-platform a megrendelő **saját felhőkörnyezetében**: egyetlen ellenőrzött hívási pont, adatkitakarás, naplózás, emberi jóváhagyás.

Egy héttel az élesítés után az AI-használat 10%-ról 90%-ra nőtt.

10% → 90% egy hét alatt

0 személyes adat a hívásban



Magyar ügyvédi iroda

Saját fejlesztésű „AI ügyvédjelölt”: precedenskeresés, **érvelési ügynökök**, és teljes **fellebbezésstervezetet előállító ügynökcsapat**.

Minden hivatkozás visszavezethető a forrásig; a jogi felelősség az ügyvédé marad.

jogpilot.ai

precedens + érvelés



Brit tanácsadó cég

A cég **teljes módszertana** tudásbázisban, ügynökökkel — a csapat a **megszokott ChatGPT-felületről** éri el.

Az ügyfél a tőlünk kapott forráskódra **saját eszközöket is épített**.

napi használat



Saját termék · e-kereskedelem

Többügynökös gyártási lánc a koncepciótól a publikálható termékig.

4 óra → 12 perc / termék

97 leszállított termék

Közös bennük

Mindegyik a megrendelő **saját környezetében** fut, **forrásmegjelöléssel** dolgozik, és a következményekkel járó lépésnél **embert kérdez**.

Hol vannak az ügynökök — és mi fogja őket vissza

AZ ÖNÖK CSAPATA



AI-KAPU

Készség-réteg (skill layer)

folyamatonként leírt, verziózott ügynök-készségek

Eszköz-szerver (MCP)

legszűkebb jogosultság · minden eszközhívás naplózva

Kormányzás

személyes adat kitakarása a hívás előtt
emberi jóváhagyás a következményes lépéseknél
teljes, visszakövethető auditnyomvonal

AZ ÖNÖK RENDSZEREI



A modell soha nem ér hozzá közvetlenül semmihez — mindig a kapun keresztül dolgozik

Nem az a kérdés, tud-e az AI tartalmat gyártani

A képesség már megvan

A nagy ügynökségi hálózatoknak van saját AI-eszköztáruk — figyelés, elemzés, krízisjelzés. **Nem ezzel versenyzünk.**

A kérdés az, hogy ez **helyben, a napi munkafolyamatban és a helyi ügyfélen** hogyan fut.


A márka oldalán bizalmatlanság van

A PR-szakemberek túlnyomó többsége már használ generatív AI-t — **miközben a márkák jelentős része aggódik amiatt, ahogy az ügynöksége használja.**

Ez nem technológiai, hanem **kontroll- és felelősségi kérdés.**

Szabályozott kategóriában — korhatár, tiltott állítások, piaconként eltérő kódexek — **egy generikus AI-eszköz önmagában nem használható.** Ami hiányzik: a kapu a generálás és a publikálás között.

Megfelelőségi kapu a generálás és a publikálás között



A gyorsaság a generálásból jön, a **védelem a kapuból**. Az elutasítás nem zsákutca: a rendszer megmondja, melyik szabályba ütközött.

Amit érdemes megépíteni — sorrendben

#	Mi	Kinek jó	Méret
1	Megfelelőségi kapu — automatikus ellenőrzés és emberi jóváhagyás minden kimenő anyagra	ügynökség + márká	közepes
2	Márka- és módszertan-betöltés — a márkaszabályok és a ház módszertana élő, kereshető tudásbázisként	ügynökség + márká	közepes–nagy
3	Kampány-adaptáció helyi piacokra — globális anyagból helyi változat, emberi lektorálással	ügynökség	kicsi–közepes
4	Krízis-előrejelzés és AI-válaszfigyelés — mit mondanak a nagy AI-asszisztensek a márkáról	ügynökség + márká	közepes
5	Sajtóanyagok és szóvivői briefek jóváhagyási folyamattal	ügynökség	kicsi

Az 1. és a 2. egy projekt: a kapu csak akkor tud ellenőrizni, ha a szabályok gépi formában megvannak.

Konkrétan mi legyen az első három hét

Amit mi csinálunk

1. Kiválasztunk **egy kampánytípust** és **egy piacot**, ahol a szabályrendszer éles.
2. Gépi formába visszük a szabályokat: **tiltott állítások, kötelező üzenetek, korhatár, jelölés.**
3. Felépítünk egy **működő kaput**: generálás, automatikus ellenőrzés, jóváhagyási lépés.
4. Végigfuttatjuk **korábbi, már publikált anyagokon** — és megnézzük, mit fogott volna meg.

Amit Önök kapnak

Működő kapu egy valódi kampánytípusra, nem demó adatokon.

Visszateszt: a korábbi anyagokon mért találati és téves riasztási arány.

Szabálykönyv gépi formában — ez marad akkor is, ha a rendszert nem velünk építik tovább.

A jogi felelősség végig a jóváhagyónál marad; a kapu nem dönt, hanem felkészít a döntésre.

Méretezés — a számítás, nem csak a végeredmény

Feltételezés (pesszimista)	Érték	Miből jön
Elvárt sebesség	40–50 token/mp / fő	Ennél lassabb esetén a fejlesztő elkapcsol — ez a használhatóság küszöbe
Egyidejűség	a csapat 40%-a	Nem mindenki küld egyszerre kérést; 40% terhelési csúcsnak pesszimista
Egy 96 GB-os GPU összesített áteresztése	≈ 4 000–6 000 token/mp	30B körüli, kvantált nyílt kódmodellen, kötegelt kiszolgálással
RAG-válasz	300–800 token, 30 token/mp	Rövid, hivatkozott válasz — nem hosszú generálás

10 fejlesztő

Csúcson 4 egyidejű kérés × 50 token/mp = **200 token/mp** — egy GPU áteresztésének töredéke.

30 fejlesztő

Csúcson 12 × 50 = **600 token/mp**. Áteresztésben még elférne egy kártyán, de **kontextus és tartalék miatt kettő a javaslat**.

150 RAG-felhasználó

50 egyidejű × 30 = **1 500 token/mp**. Egy GPU elég; a szűk keresztmetszet itt **a keresés, nem a modell**.

A számok **mai listaár-nagyságrendek és mérés nélküli becslések**, nem ajánlat. A 0. fázis pont azért van, hogy ezeket a saját kódjukon mért adatokra cseréljük.

Három méret — ugyanaz a szoftver, más vas

0. fázis — mérés

1 db munkaállomás-GPU (24–48 GB)
kis kódmodell, egy modul
meglévő vagy kölcsöngép

≈ 0 beruházás

5–10 fejlesztő

1× 96 GB GPU
32 mag CPU · 256 GB RAM · 4 TB NVMe
ugyanaz kiszolgál 100–150 RAG-felhasználót

≈ €25–30 ezer

20–30 fejlesztő

2× 96 GB GPU
64 mag CPU · 512 GB RAM · 8 TB NVMe
tartalék kapacitás és nagyobb kontextus

≈ €45–55 ezer

Ami az árban nincs benne

Szünetmentes táp, hálózat, rack, hűtés és üzemeltetés. Terhelés alatt **1–1,5 kW** fogyasztással érdemes számolni GPU-nként.

Miért nem H100-cal számolunk

Ezen a terhelésen **nem az áteresztés a szűk keresztmetszet**, hanem a memória és az üzemeltetés. A drágább adatközponti kártya itt nem vásárol több használhatóságot.